

**I'm Something of a Painter Myself : Use GANs to create art - will you be
the next Monet?**



00000099782 Raiyan

00000099540 Fernando

00000098250 Marcello Adi

00000100226 Rama Harrison

00000099747 Varrent Lionel Kusnadi

PROGRAM STUDI SISTEM INFORMASI
FAKULTAS TEKNIK DAN INFORMATIKA
UNIVERSITAS MULTIMEDIA NUSANTARA
TANGERANG

DAFTAR ISI

DAFTAR ISI.....	2
BAB I.....	4
PENDAHULUAN.....	4
1.1 Latar Belakang.....	4
1.2 Rumusan Masalah.....	5
1.3 Tujuan Penelitian.....	5
1.4 Manfaat Penelitian.....	5
BAB II.....	7
LANDASAN TEORI.....	7
2.1 Generative Adversarial Networks (GAN).....	7
2.2 Image-to-Image Translation.....	7
2.3 CycleGAN.....	7
2.4 Arsitektur Generator dan Discriminator.....	8
2.5 Fungsi Loss.....	8
2.6 Evaluasi Kualitas Gambar: MiFID.....	9
BAB III.....	10
METODOLOGI.....	10
3.1 Pendekatan Penelitian.....	10
3.2 Arsitektur Model.....	10
3.2.1 Generator.....	11
3.2.2 Discriminator.....	11
3.3 Dataset.....	11
3.3.1 Struktur Dataset.....	12
3.3.2 Karakteristik Dataset.....	12
3.4 Pelatihan Model.....	13
3.4.1 Jenis Loss.....	13
3.5 Evaluasi dan Validasi.....	14
3.5.1 Evaluasi Kualitatif.....	14
3.5.2 Evaluasi Kuantitatif.....	14
3.6 Implementasi.....	14
BAB IV.....	15
HASIL DAN ANALISIS.....	15
4.1 Hasil Pelatihan Model.....	15
4.1.1 Output Gambar.....	15
4.1.2 Jumlah Gambar.....	17
4.1.3 Skor FID.....	17
4.2 Analisis Performa.....	18
4.2.1 Transformasi Gaya.....	18
4.2.2 Konsistensi Siklus.....	19

4.2.3 Tren FID.....	19
4.3 Pembahasan.....	19
BAB V.....	20
KESIMPULAN DAN SARAN.....	20
5.1 Kesimpulan.....	20
5.2 Saran.....	21
DAFTAR PUSTAKA.....	23

BAB I

PENDAHULUAN

1.1 Latar Belakang

Kemajuan pesat dalam bidang *deep learning* telah melahirkan banyak inovasi pendekatan dalam pengolahan *digital image*, salah satunya adalah ***image-to-image translation***, sebuah teknik yang memungkinkan konversi gambar dari satu domain visual ke domain lain. Teknik ini telah digunakan secara luas dalam berbagai aplikasi seperti peningkatan resolusi gambar (*super-resolution*), pewarnaan gambar hitam putih, segmentasi semantik, hingga *style transfer*.

Salah satu pendekatan yang paling menonjol dalam bidang ini adalah ***Generative Adversarial Networks (GANs)***, yang diperkenalkan oleh Goodfellow et al. (2014). GAN terdiri dari dua jaringan saraf: **generator** yang bertugas menghasilkan data tiruan, dan **discriminator** yang bertugas membedakan data tiruan dari data nyata. Kedua jaringan ini dilatih secara adversarial hingga generator mampu menghasilkan data yang realistis.

Dalam konteks seni visual, khususnya lukisan, GAN membuka peluang baru untuk menggabungkan teknologi dengan kreativitas manusia. Teknik style transfer memungkinkan gambar biasa (foto) diubah menjadi lukisan dalam gaya visual seniman terkenal, seperti Claude Monet, yang dikenal dengan gaya impresionismenya. Salah satu pendekatan terkini yang banyak digunakan untuk tugas ini adalah CycleGAN, yang mampu melakukan transformasi gaya tanpa memerlukan data berpasangan (*unpaired image-to-image translation*).

Penelitian ini mengadopsi pendekatan CycleGAN untuk mentransformasikan gambar foto menjadi lukisan bergaya Monet. Dataset yang digunakan merupakan bagian dari kompetisi Kaggle "Monet2Photo", yang menyediakan ribuan citra foto dan lukisan Monet. Model dilatih dan dievaluasi menggunakan metrik Fréchet Inception Distance (FID) untuk menilai seberapa realistis gambar hasil generasi jika dibandingkan dengan lukisan asli.

1.2 Rumusan Masalah

Berdasarkan latar belakang tersebut, maka rumusan masalah yang diangkat dalam penelitian ini adalah:

1. Bagaimana cara mengimplementasikan model CycleGAN untuk tugas style transfer dari domain foto ke domain lukisan bergaya Monet?
2. Seberapa efektif model yang dikembangkan dalam menghasilkan gambar yang menyerupai lukisan Monet baik secara visual maupun kuantitatif?
3. Metrik evaluasi apa yang paling tepat untuk menilai kualitas hasil style transfer, dan bagaimana performa model berdasarkan metrik tersebut?

1.3 Tujuan Penelitian

Adapun tujuan dari penelitian ini adalah sebagai berikut:

1. Mengimplementasikan model **CycleGAN** untuk melakukan transformasi gaya visual dari foto ke lukisan Monet tanpa data yang berpasangan.
2. Menghasilkan gambar yang secara estetika menyerupai karakteristik gaya lukisan **Claude Monet**.
3. Mengevaluasi hasil generasi model menggunakan metrik kuantitatif seperti **Fréchet Inception Distance (FID)**.

1.4 Manfaat Penelitian

Hasil dari penelitian ini diharapkan dapat memberikan manfaat sebagai berikut:

1. Akademik: Menjadi referensi pengembangan sistem style transfer berbasis GAN dalam bidang visi komputer dan seni digital.

2. Teknologis: Memberikan contoh implementasi model GAN secara efisien menggunakan framework TensorFlow dengan dukungan TPU.
3. Praktis dan Kreatif: Menawarkan solusi otomatisasi dalam produksi konten artistik digital yang dapat dimanfaatkan dalam bidang desain, pendidikan seni, maupun aplikasi hiburan dan media sosial.

BAB II

LANDASAN TEORI

2.1 *Generative Adversarial Networks (GAN)*

Generative Adversarial Networks (GAN) pertama kali diperkenalkan oleh Ian Goodfellow pada tahun 2014 sebagai pendekatan dalam *deep learning* untuk menghasilkan data baru yang menyerupai data pelatihan. Arsitektur dasar *GAN* terdiri dari dua jaringan saraf yaitu *generator* dan *discriminator*. *Generator* bertugas menghasilkan data palsu (misalnya gambar), sementara *discriminator* bertugas membedakan apakah data yang diberikan merupakan data asli atau hasil buatan *generator*. Proses pelatihan *GAN* bersifat adversarial, di mana kedua model saling berlomba. *Generator* mencoba menipu *discriminator*, sedangkan *discriminator* belajar untuk mendeteksi penipuan tersebut.

2.2 *Image-to-Image Translation*

Image-to-image translation adalah proses mentransformasikan satu representasi visual ke representasi lain, misalnya dari foto ke lukisan atau dari gambar hitam-putih ke gambar berwarna. Dalam penelitian ini, proses transformasi dilakukan dari gambar foto ke gaya lukisan Claude Monet. Proyek ini menggunakan pendekatan unpaired image translation, yaitu tanpa membutuhkan pasangan gambar sebelum-dan-sesudah (paired dataset).

2.3 *CycleGAN*

CycleGAN adalah arsitektur *GAN* yang dikembangkan untuk mengatasi masalah *image-to-image translation* tanpa membutuhkan data berpasangan (*unpaired data*). Dalam *CycleGAN*, terdapat dua *generator* (G dan F) dan dua *discriminator* (D_X dan D_Y). *CycleGAN* memperkenalkan *cycle consistency loss*, yang memastikan bahwa

jika sebuah gambar dari domain X diubah ke domain Y, lalu dikembalikan ke domain X, hasil akhirnya harus menyerupai gambar awal.

Arsitektur *CycleGAN* sangat berguna untuk tugas-tugas seperti *style transfer*, *season transfer*, dan transformasi objek tanpa dataset teranotasi secara eksplisit. Dalam konteks penelitian ini, *CycleGAN* digunakan untuk mentransformasikan gambar-gambar foto biasa menjadi gambar bergaya lukisan Monet.

2.4 Arsitektur Generator dan Discriminator

Generator dirancang menggunakan struktur mirip U-Net dengan encoder-decoder, dan *skip connection* untuk mempertahankan fitur penting dari gambar input. Proses ini membantu dalam menjaga struktur semantik gambar saat dilakukan transformasi gaya.

Discriminator menggunakan pendekatan *PatchGAN*, yang mengevaluasi keaslian citra dalam patch kecil daripada keseluruhan gambar. Hal ini membuat model lebih fokus terhadap detail lokal daripada global, yang penting dalam style transfer seperti lukisan Monet.

2.5 Fungsi Loss

CycleGAN menggunakan kombinasi dari beberapa fungsi *loss* untuk memastikan pelatihan stabil dan menghasilkan gambar yang realistis:

- *Adversarial loss* untuk mengukur kemampuan *generator* dalam menipu *discriminator*.
- *Cycle consistency loss* untuk memastikan transformasi gambar kembali ke domain asal.
- *Identity loss* untuk mempertahankan fitur asli jika gambar dari domain target dimasukkan ke *generator* yang seharusnya tidak mengubah gambar tersebut.

2.6 Evaluasi Kualitas Gambar: MiFID

Untuk mengevaluasi hasil dari model, digunakan *MiFID* (*Memorization-informed Fréchet Inception Distance*). Skor *MiFID* menghitung seberapa dekat distribusi fitur dari gambar hasil generator dengan gambar-gambar asli. Skor yang lebih rendah menandakan kualitas hasil yang lebih tinggi dan lebih realistis.


BAB III

METODOLOGI

3.1 Pendekatan Penelitian

Penelitian ini menggunakan pendekatan kuantitatif eksperimental berbasis deep learning untuk melakukan transformasi gambar dari domain foto biasa menjadi gambar dengan gaya lukisan Claude Monet. Model yang digunakan dalam penelitian ini adalah Cycle-Consistent Generative Adversarial Network (CycleGAN), yang mampu melakukan image-to-image translation tanpa membutuhkan dataset yang berpasangan.

3.2 Arsitektur Model



Gambar 3.2.1 Visualisasi konsep arsitektur CycleGAN

Terdapat dua buah generator, yaitu:

- Generator G (Photo $\rightarrow$ Monet)
- Generator F (Monet $\rightarrow$ Photo)

Dua buah discriminator, yaitu:

- D_Y : Discriminator Monet
- D_X : Discriminator Photo

Kedua generator digunakan untuk mentransformasi gambar dari satu domain ke domain lain dan kembali lagi, sedangkan kedua discriminator bertugas membedakan antara gambar asli dan gambar hasil generator.

3.2.1 Generator


Struktur generator terdiri dari encoder dan decoder yang dibangun dengan menggunakan layer convolutional dan transposed convolutional, serta instance normalization. Skip connection digunakan untuk menjaga informasi penting selama proses encoding dan decoding.

3.2.2 Discriminator

Discriminator menggunakan pendekatan PatchGAN, yaitu mengevaluasi keaslian gambar berdasarkan patch-patch kecil dalam gambar. Hal ini memungkinkan model untuk lebih fokus pada detail lokal dan tekstur dari citra.

3.3 Dataset

Dataset yang digunakan dalam penelitian ini berasal dari *kaggle competition* yang berjudul “*I’m Something of a Painter Myself*” (<https://www.kaggle.com/competitions/gan-getting-started/overview>). Dataset ini berfokus pada transformasi gambar dari domain foto asli (real photo) ke domain lukisan bergaya Monet (Monet-style painting) dengan menggunakan pendekatan unpaired image-to-image translation.



Gambar 3.3.2 I'm Something of a Painter Myself Kaggle Competition

3.3.1 Struktur Dataset

Dataset dibagi menjadi empat direktori utama:

- monet_jpg – 300 lukisan Monet dalam format JPEG, berukuran 256×256 pixel.
- monet_tfrec – 300 lukisan Monet yang sama dalam format TFRecord.
- photo_jpg – 7028 foto nyata dalam format JPEG, berukuran 256×256 pixel.
- photo_tfrec – 7028 foto nyata dalam format TFRecord.

Kedua format (JPEG dan TFRecord) disediakan agar peserta dapat memilih pendekatan sesuai preferensi atau kebutuhan teknis. Dalam penelitian ini, kami menggunakan format JPEG karena lebih umum digunakan dan mudah diproses dengan pustaka Python seperti TensorFlow dan PyTorch.

3.3.2 Karakteristik Dataset

- Unpaired Dataset: Gambar dalam domain Monet dan domain Foto tidak memiliki pasangan satu lawan satu (unpaired). Hal ini sesuai dengan pendekatan CycleGAN, yang memang

dirancang untuk dapat belajar melakukan konversi antar domain tanpa memerlukan pasangan gambar eksplisit.

- Resolusi Seragam: Semua gambar sudah memiliki ukuran tetap, yaitu 256x256 piksel, yang memudahkan preprocessing dan pemrosesan dalam model.
- Distribusi Data: Terdapat ketidakseimbangan data antara kedua domain, dengan jumlah foto yang jauh lebih banyak dibanding lukisan Monet (7028 vs 300). Oleh karena itu, teknik augmentasi data atau penyesuaian sampling mungkin diperlukan untuk mengurangi bias selama pelatihan.

3.4 Pelatihan Model

Model dilatih menggunakan TensorFlow dan library Keras, dengan konfigurasi pelatihan sebagai berikut:

- Optimizer: Adam Optimizer
- Learning Rate: 0.0002
- Beta1: 0.5
- Epochs: 30
- Batch Size: 4

3.4.1 Jenis Loss

Selama proses pelatihan, model mengoptimasi tiga jenis fungsi kerugian (loss function):

- Adversarial Loss: Untuk memastikan bahwa gambar hasil generator tidak dapat dibedakan oleh discriminator.
- Cycle Consistency Loss: Menjamin bahwa gambar yang diubah dan kemudian dikembalikan tetap serupa dengan input aslinya.
- Identity Loss (opsional): Untuk memastikan bahwa gambar dari domain Y yang dimasukkan ke G tetap mempertahankan karakteristik Monet.

3.5 Evaluasi dan Validasi

Untuk menilai kualitas model, dilakukan evaluasi secara kuantitatif dan kualitatif:

3.5.1 Evaluasi Kualitatif

Dilakukan dengan menampilkan sampel gambar hasil transformasi dan membandingkannya secara visual terhadap lukisan Monet yang asli. Hasil transformasi yang mendekati gaya lukisan Monet menunjukkan keberhasilan model.

3.5.2 Evaluasi Kuantitatif

Menggunakan metrik:

- MiFID (Memorization-informed Fréchet Inception Distance): Metrik ini menghitung jarak distribusi fitur antara gambar asli dan hasil transformasi.
- Skor MiFID yang lebih rendah menunjukkan bahwa gambar hasil generator lebih menyerupai gambar asli Monet.

3.6 Implementasi

Model dan proses pelatihan diimplementasikan dalam Python menggunakan tools berikut:

- TensorFlow & Keras: Untuk membangun dan melatih model neural network.
- Matplotlib & PIL: Untuk visualisasi hasil gambar.
- Google Colab/Jupyter Notebook: Untuk menjalankan eksperimen dan menyimpan hasil.
- Struktur folder proyek dibagi menjadi:
 - /monet_jpg/: Dataset Monet
 - /photo_jpg/: Dataset Foto
 - /generated_samples/: Hasil gambar transformasi
- cycle_gan.py: Script utama pelatihan
- train_cycle_gan.ipynb: Notebook pelatihan dan evaluasi

BAB IV

HASIL DAN ANALISIS

4.1 Hasil Pelatihan Model

Pelatihan model Cycle Generative Adversarial Networks (CycleGAN) dilakukan selama 50 epoch, dengan evaluasi awal pada 10 epoch, untuk menghasilkan gambar bergaya Monet dari 300 foto biasa dalam dataset kompetisi Kaggle "*I'm Something of a Painter Myself*". Berikut adalah hasil utama yang diperoleh:


4.1.1 Output Gambar

Model berhasil menghasilkan gambar bergaya Monet menggunakan Generator G (Photo → Monet). Gambar yang dihasilkan menunjukkan karakteristik gaya Monet, seperti sapuan kuas lembut dan palet warna cerah, tetapi detail spasial pada foto asli sering kali kabur. Berikut adalah beberapa contoh transformasi yang dihasilkan:




Gambar 4.1.1 Image 1 Transformasi Photo → Monet

Gambar ini menunjukkan transformasi foto pemandangan awan menjadi gaya lukisan Monet oleh Generator G setelah 50 epoch pelatihan. Warna biru dan putih mendominasi, tetapi detail pohon menjadi kabur.



Gambar 4.1.2 Image 2 Transformasi Photo → Monet

Gambar ini mengilustrasikan transformasi foto hutan menjadi gaya Monet. Warna hijau dan coklat dipertahankan, tetapi tekstur pohon menjadi lebih impressionis.



Gambar 4.1.3 Image 3Transformasi Photo → Monet


Gambar ini menunjukkan transformasi foto jembatan melengkung menjadi gaya lukisan Monet oleh Generator G setelah 50 epoch pelatihan. Struktur jembatan menjadi lebih impressionis dengan warna cerah, tetapi detail garisnya kabur.

4.1.2 Jumlah Gambar

Model menghasilkan lebih dari 7.000 gambar, memenuhi syarat minimum kompetisi (7.000 hingga 10.000 gambar), meskipun prosesnya lambat akibat keterbatasan hardware.

4.1.3 Skor FID

Skor Fréchet Inception Distance (FID) diukur selama pelatihan. Pada 10 epoch, skor FID masih tinggi, menunjukkan perbedaan signifikan antara gambar yang dihasilkan dan lukisan Monet asli. Setelah 50 epoch, skor FID menurun, mengindikasikan peningkatan kualitas gambar.



Gambar 4.1.4 Grafik FID Score During Training

Grafik ini menunjukkan penurunan skor FID selama 50 epoch pelatihan, mengindikasikan peningkatan kualitas gambar yang dihasilkan seiring waktu, skor FID turun dari 95,108 pada epoch 1 menjadi 12,80 pada epoch 50. Penurunan signifikan terjadi pada 20 epoch pertama, dengan FID mencapai 0,8845 pada epoch 20, menunjukkan model belajar dengan cepat. Namun, setelah epoch 20, FID mengalami fluktuasi kecil sebelum stabil di 12,80, mengindikasikan peningkatan kualitas gambar meskipun ada ketidakstabilan pelatihan.

4.2 Analisis Performa

Performa model dievaluasi menggunakan metrik Memorization-informed Fréchet Inception Distance (MiFID), standar kompetisi Kaggle, dengan skor FID sebagai indikator tambahan:

4.2.1 Transformasi Gaya

Pada Gambar 4.1.1, 4.1.2 dan 4.1.3 menunjukkan bahwa Generator G berhasil menangkap gaya Monet pada berbagai jenis pemandangan. Gambar 4.1.1 (pemandangan awan) menonjolkan warna biru dan putih khas Monet, tetapi detail pohon hilang. Gambar 4.1.2 (hutan) mempertahankan warna alami, namun tekstur menjadi impresionis. Gambar 4.1.3 (jembatan) menunjukkan transformasi struktur arsitektur, tetapi garis jembatan menjadi kabur. Secara keseluruhan, model berhasil

menerapkan gaya Monet, tetapi tantangan utama adalah menjaga detail spasial sekaligus mencapai realisme.

4.2.2 Konsistensi Siklus

Karena hasil output hanya menunjukkan transformasi Photo $\rightarrow$ Monet, analisis siklus Photo $\rightarrow$ Monet $\rightarrow$ Photo terbatas pada teori. Siklus ini seharusnya menunjukkan Generator F mengembalikan gambar ke domain foto dengan akurasi memadai, menjaga konsistensi melalui cycle-consistency loss.

4.2.3 Tren FID

Pada Gambar 4.4 menunjukkan penurunan skor FID dari 95,108 pada epoch 1 menjadi 12,80 pada epoch 50. Penurunan cepat pada 20 epoch pertama menunjukkan pembelajaran yang efektif, tetapi fluktuasi setelahnya mengindikasikan ketidakstabilan pelatihan. FID akhir sebesar 12,80 menunjukkan gambar yang dihasilkan cukup mirip dengan lukisan Monet, tetapi belum optimal untuk skor MiFID.

4.3 Pembahasan

Hasil pelatihan menunjukkan bahwa CycleGAN efektif untuk tugas unpaired image-to-image translation dalam kompetisi ini. Skor FID akhir sebesar 12,80 (Gambar 4.4) mengindikasikan bahwa gambar yang dihasilkan cukup mirip dengan lukisan Monet, meskipun fluktuasi FID setelah epoch 20 menunjukkan ketidakstabilan pelatihan. Gambar output (Gambar 4.1, 4.2, dan 4.3) berhasil menangkap gaya Monet, tetapi kehilangan detail spasial menjadi tantangan utama. Dengan hardware yang lebih baik dan pelatihan lebih lama, kualitas gambar dan skor MiFID dapat ditingkatkan.

BAB V

KESIMPULAN DAN SARAN

5.1 Kesimpulan

Penelitian ini bertujuan untuk mengimplementasikan model Cycle Generative Adversarial Networks (CycleGAN) guna melakukan transformasi gaya visual dari foto ke lukisan bergaya Monet dalam kompetisi Kaggle "I'm Something of a Painter Myself", serta mengevaluasi hasilnya secara kualitatif dan kuantitatif. Berdasarkan hasil dan analisis yang telah dilakukan pada Bab 4, berikut adalah kesimpulan utama:

1. Implementasi CycleGAN: Model CycleGAN berhasil diimplementasikan untuk tugas unpaired image-to-image translation menggunakan dataset kompetisi yang terdiri dari 300 lukisan Monet dan 7.028 foto biasa. Proses pelatihan dilakukan selama 50 epoch dengan generator dan discriminator yang dirancang sesuai arsitektur CycleGAN, seperti yang dijelaskan pada Bab 3.
2. Hasil Transformasi Gaya: Model mampu menghasilkan gambar bergaya Monet dari foto biasa, dengan karakteristik gaya Monet seperti sapuan kuas lembut dan palet warna cerah, sebagaimana ditunjukkan pada Gambar 4.1.1 , 4.1.2 dan 4.1.3. Namun, kehilangan detail spasial pada gambar hasil transformasi menjadi tantangan utama, terutama pada struktur seperti pohon dan garis jembatan.
3. Performa Model: Model menghasilkan lebih dari 7.000 gambar, memenuhi syarat kompetisi. Berdasarkan metrik Fréchet Inception Distance (FID), skor FID turun dari 95,108 pada epoch 1 menjadi 12,80 pada epoch 50. Pada gambar 4.1.4, menunjukkan peningkatan kualitas gambar seiring waktu. Namun, fluktuasi FID setelah epoch 20 mengindikasikan ketidakstabilan pelatihan, dan skor ini belum optimal untuk metrik Memorization-informed Fréchet Inception Distance (MiFID) yang lebih ketat.
4. Efektivitas dan Tujuan Penelitian: CycleGAN terbukti efektif untuk tugas style transfer tanpa data berpasangan, sebagaimana tujuan penelitian di Bab 1. Gambar yang dihasilkan secara estetika menyerupai gaya lukisan Monet, meskipun ada keterbatasan dalam menjaga

detail spasial. Evaluasi kuantitatif menggunakan FID menunjukkan hasil yang cukup baik, tetapi masih ada ruang untuk perbaikan pada skor MiFID.

Secara keseluruhan, penelitian ini berhasil menjawab rumusan masalah dengan mengimplementasikan CycleGAN untuk *style transfer* dan mengevaluasi performanya. Hasilnya memberikan kontribusi akademik dan praktis dalam bidang visi komputer dan seni digital, sesuai dengan manfaat penelitian yang diharapkan.

5.2 Saran

Berdasarkan kendala yang dihadapi selama penelitian, berikut adalah beberapa saran untuk pengembangan lebih lanjut:

1. Optimalisasi Hardware: Proses pelatihan lambat akibat keterbatasan hardware. Penggunaan GPU melalui platform cloud computing seperti Google Collab dapat mempercepat pelatihan dan memungkinkan iterasi lebih banyak untuk meningkatkan kualitas gambar dan skor MiFID.
2. Efisiensi Pra-pemrosesan: Pengolahan data memakan waktu karena kompleksitas dataset. Mengotomatisasi pra-pemrosesan dengan skrip dapat meningkatkan efisiensi, sehingga lebih banyak waktu dapat dialokasikan untuk pelatihan dan evaluasi.
3. Peningkatan Detail Gambar: Kehilangan detail spasial pada gambar hasil transformasi Pada Gambar 4.1.1 , 4.1.2 dan 4.1.3 ,dapat diatasi dengan menyesuaikan arsitektur generator atau loss function, misalnya dengan menambahkan perceptual loss untuk mempertahankan struktur gambar.
4. Stabilitas Pelatihan: Fluktuasi FID setelah epoch 20 Pada Gambar 4.1.4 menunjukkan ketidakstabilan pelatihan. Melatih model untuk lebih banyak epoch atau menyesuaikan hiperparameter, seperti learning rate, dapat membantu mencapai konvergensi yang lebih stabil dan meningkatkan skor MiFID.
5. Eksperimen Tambahan: Penelitian lebih lanjut dapat dilakukan dengan mencoba arsitektur GAN lain, seperti StyleGAN, atau menggunakan dataset yang lebih besar untuk

meningkatkan generalisasi model. Selain itu, evaluasi kualitatif dapat diperluas dengan melibatkan penilaian subjektif dari seniman atau pakar seni untuk menilai estetika gambar.

Saran-saran ini diharapkan dapat menjadi acuan untuk meningkatkan performa model dan kualitas hasil style transfer dalam penelitian mendatang, sekaligus memperluas aplikasi teknologi GAN dalam seni digital.

DAFTAR PUSTAKA

- [1] I. Goodfellow *et al.*, “Generative adversarial nets,” in *Advances in Neural Information Processing Systems*, vol. 27, 2014. [Online]. Available: https://papers.nips.cc/paper_files/paper/2014/file/5ca3e9b122f61f8f06494c97b1afccf3-Paper.pdf
- [2] Zhu, J. Y., Park, T., Isola, P., & Efros, A. A. (2017). Unpaired image-to-image translation using cycle-consistent adversarial networks. In Proceedings of the IEEE International Conference on Computer Vision (ICCV), 2223–2232. <https://doi.org/10.1109/ICCV.2017.244>
- [3] Gatys, L. A., Ecker, A. S., & Bethge, M. (2016). Image style transfer using convolutional neural networks. In Proceedings of the IEEE conference on computer vision and pattern recognition (CVPR), 2414–2423. <https://doi.org/10.1109/CVPR.2016.265>
- [4] TensorFlow Authors. (n.d.). CycleGAN Tutorial. TensorFlow. <https://www.tensorflow.org/tutorials/generative/cyclegan>
- [5] Kaggle. (n.d.). I'm Something of a Painter Myself. Retrieved from <https://www.kaggle.com/competitions/gan-getting-started>
- [6] Isola, P., Zhu, J. Y., Zhou, T., & Efros, A. A. (2017). Image-to-image translation with conditional adversarial networks. In Proceedings of the IEEE conference on computer vision and pattern recognition (CVPR), 1125–1134. <https://doi.org/10.1109/CVPR.2017.632>
- [7] Radford, A., Metz, L., & Chintala, S. (2016). Unsupervised representation learning with deep convolutional generative adversarial networks. In International Conference on Learning Representations (ICLR). <https://arxiv.org/abs/1511.06434>
- [8] Yi, Z., Zhang, H., Tan, P., & Gong, M. (2017). DualGAN: Unsupervised dual learning for image-to-image translation. In Proceedings of the IEEE International Conference on Computer Vision (ICCV), 2849–2857. <https://doi.org/10.1109/ICCV.2017.309>
- [9] Heusel, M., Ramsauer, H., Unterthiner, T., Nessler, B., & Hochreiter, S. (2017). GANs trained by a two time-scale update rule converge to a local Nash equilibrium. In Advances in neural information processing systems (NeurIPS), 30. <https://arxiv.org/abs/1706.08500>